期末專題提案：Hybrid Technical & Price Action Agent (Hybrid TPA-Agent)

結合確定性供需區、機器學習與大型語言模型之可靠短線交易輔助系統

專題組員：7115056027 陳柏安 ｜ 7114056115 侯佳旻 ｜ 7114068023 陳威碩 ｜ 7114068027 陳沐德 ｜ 7115068026 古富綿

指導規範：2020 A-Z SOP 學術論文寫作標準（整合實證與決策可靠性深度解析版）

摘要 (Abstract) —— 對應 A–F 規範深度解析

【A. Attention Getter 動機與引題】短線交易面臨市場雜訊、資訊過載與快速決策壓力。SEBI 於 2026 年發布的報告顯示，FY26 個人股票衍生品交易者中高達 87.7% 出現虧損，且交易經驗不必然轉化為穩定獲利，凸顯交易輔助系統除追求預測準確度外，更須兼顧嚴格的風險管理與決策可靠性。

【B. But/However 現存挑戰與缺口】傳統指標難以完整表達價格空間結構；大型語言模型（LLM）雖能進行情境判讀，其交易決策仍極易受到生成隨機性（溫度、種子）影響而產生變異。此外，近期研究（如 FinForesight）指出，歷史資訊洩漏可能大幅高估金融 AI 的預測能力，顯示單純的回測績效已不足以證明系統在實戰中的可靠度。

【C. Cure 核心解藥】本研究提出 Hybrid TPA-Agent，整合確定性供需區演算法、XGBoost 條件機率模型與大型語言模型，建立「數值運算與語意判讀徹底分離」的短線交易輔助架構，將系統整合轉化為可量化與可否證的功能分工假說。

【D. Development 方法發展與架構整合】系統以演算法客觀辨識供需區與關鍵價位，由 XGBoost 估計交易成功機率，再由 LLM 整合價格行為證據；進場、停損、部位及風報比則交由程式化風控引擎計算，並導入嚴格的「不交易（WAIT/NO_TRADE）機制」與人工覆核，確保決策邏輯的可追溯性。

【E. Experiments 實驗設計與驗證場景】採用 BTC/USDT 與 ETH/USDT 之 5m/15m 歷史資料，比較傳統指標、純機器學習、純語言模型與消融架構。實驗設計除考量交易成本外，更特別規劃重複執行一致性檢驗、時點資訊控制（Point-in-time）、極端行情壓力測試及前瞻模擬驗證。

【F. Findings 預期貢獻與目標】預期建立可追溯、可複現的研究原型，量化各模組對淨績效、決策一致性與風控遵循的實質增益。本研究旨在釐清 LLM 於金融交易的適用邊界，將最高回撤抑制目標設為 12% 內，為高可靠度的金融人工智慧提供堅實的實證研究基礎。

第一章：緒論 (Introduction) ── 對應 G–L 規範深度解析

1.1 研究背景與問題重要性 (G: General)

在現代金融市場中，短線交易與日內當沖吸引了大量零售投資人。然而，本研究關注的核心並非單純建立「預測漲跌的 AI」，而是探討：**如何讓交易 AI 在高雜訊與極端行情下，產出受風控約束、具有可追溯證據，且能重複驗證的交易決策（包含準確判斷何時「不應交易」）。**金融資產的高頻時序具備高度非平穩性，零售交易員在高壓下極易陷入認知疲勞與情緒偏誤，導致災難性虧損。原提案已規劃供需區分析、機器學習與 LLM 的分工協作，本報告進一步將焦點收斂至「功能分工是否能實質改善決策可靠性」。

1.2 監管數據啟示：持續交易不等於持續獲利 (H: However)

印度證券交易委員會 (SEBI) 於 2026 年發布的《Trading Behaviour of Individual Traders in the Equity Derivatives Segment》報告指出，FY26 涵蓋的 786 萬名個人交易者中，虧損比例高達 87.7%。更甚者，FY22–FY26 五年皆持續交易者中，僅 0.5% 每年皆獲利；前兩年均虧損且持續交易者，下一年仍虧損的比例高達 90–92%。這項強而有力的監管證據顯示：交易經驗的累積不必然轉化為穩定成果，研究不能只追求「更多交易訊號」，更須檢驗風險控制、曝險限制與「不交易機制」對決策品質的改善。

1.3 新聞案例：極端行情對風控的挑戰

Reuters 於 2025 年 10 月報導，加密貨幣市場在兩日內劇烈下跌，槓桿部位強制平倉規模超過 190 億美元，BTC 跌幅逾 14%。此類由恐慌賣壓與低流動性共振引發的極端行情，是檢驗量化系統的絕佳壓力測試場景。本研究將此類事件納入，旨在檢驗系統是否能在異常波動時減少新開倉、拒絕交易是否真正降低了損失，以及在市場狀態快速轉變時，各模組的失效順序與邊界。

1.4 既有文獻演進與批判性分析 (I: In Literature & J: Judgement)

量化交易與 AI 在金融領域的演進經歷了傳統指標、機器學習（如 XGBoost），至近期的 LLM 多代理人架構（如 TradingAgents）。然而，最新研究指出了兩大嚴峻挑戰：第一，ACM 2026 年的 TradingAgents 研究顯示，LLM 交易決策在不同溫度與隨機種子下存在極大變異，生成隨機性嚴重影響決策重現性；第二，2026 年 FinForesight 研究證實，歷史資訊洩漏（Data Leakage）會使模型的回憶能力看起來像預測能力，時點控制（Point-in-time）介入後，評估分數差距縮減高達 76%。現有研究多忽視了此類決策一致性與資訊洩漏風險，缺乏兼顧空間結構、機率統計與嚴謹重現性的有機架構。

1.5 本研究核心貢獻 (K: Keypoint / Contributions)

為解決上述理論與實務缺口，本專題提出 Hybrid TPA-Agent，其核心貢獻為：

1. **建立數值與語意分離之可靠原型：**提出解耦式架構，由確定性演算法處理空間，XGBoost 處理機率，LLM 專注情境，量化比較分工後的錯誤率與決策一致性。
2. **將主觀價格行為客觀化與可檢驗化：**建立明確的供需區特徵、標籤與更新規則，檢查可重複性及其對模型表現的影響。
3. **引入時點控制與不交易（WAIT）評估：**建立兼顧績效、可靠性與時點有效性的驗證流程，評估不交易機制避免的損失是否能補償錯失的機會，界定 AI 的適用邊界。

1.3 既有文獻演進與批判性分析 (I: In Literature & J: Judgement)

綜觀量化交易與人工智慧在金融領域之演進歷史，學界與業界大體經歷了三個主要階段：第一階段為基於硬性統計規則與單一指標交叉之傳統量化策略；第二階段為利用特徵工程與機器學習演算法（如 Random Forest、XGBoost）預測次根 K 線漲跌趨勢；第三階段為近年興起之生成式 LLM 多代理人架構（如 TradingAgents, TradingGPT 等）。

批判性審視既有研究之本質缺陷：第一階段指標派嚴重滯後且缺乏空間情境；第二階段機器學習派視數據為均勻特徵切片，忽視了金融市場中極其關鍵的『不連續空間支撐阻力結構』；第三階段純 LLM 派則陷入生成式語言模型的隨機性與計算黑箱，無法滿足金融風控對 100% 確定性數學期望值的嚴格要求。現有研究在此三大維度中呈現割裂狀態，缺乏有機整合之架構。

1.4 本研究核心貢獻 (K: Keypoint / Contributions)

為根本解決上述理論與實務缺口，本專題提出 Hybrid TPA-Agent 智慧代理人系統，其核心技術與學術貢獻歸納如下：

1. **首創空間感知與推理分離之短線 AI 代理人架構：**提出三層解耦式架構，分別由確定性空間演算法、機器學習分類器與大型語言模型各司其職，從架構底層根除了純 AI 金融系統之數值與空間幻覺。
2. **實現主觀價格行為學與客觀機器學習之深度融合：**將專業操盤手高度依賴的主觀價格行為學（裸 K、市場結構轉折、供需失衡）轉化為客觀、可程式重現之確定性演算法，並結合 XGBoost 萃取多維特徵進行精準條件勝率預測。
3. **建立嚴格正期望值風控機制與標準化開源規範：**落實動態風險報酬比（RR）與數學期望值雙門檻過濾網，唯有在預測勝率與空間風報比同時達標時方核准交易，並開源完整的 DESIGN.md 系統規格書以促進量化社群之複現與擴展。

1.5 本文架構組織 (L: List Organization / Roadmap)

本文其餘章節之整體脈絡安排如下：第二節（Related Work）對既有研究進行系統化分類並建立多維度對比矩陣；第三節（Deep Research）深度剖析驅動本系統之五大核心思維、三大專業爭論及十個關鍵邊界問題；第四節（Proposed Scheme）詳述四層八模組之系統架構、核心虛擬碼（Algorithm 1）、穿透式實例解析與時間複雜度分析；第五節（Simulation & Experiments）詳細規劃評估指標體系、基準消融實驗、資料集設定與參數敏感度分析；第六節（Conclusion & Future Work）總結研究成果並提出未來工程擴展方向。

第二章：相關研究與缺口分析 (Related Work) —— 對應 M–O 規範深度解析

2.1 生成隨機性與交易決策重現性

2026 年 4 月發表於 ACM 會議的〈Reproducibility in the TradingAgents Framework〉研究了模型溫度、隨機種子對交易結果的影響。在溫度為 1 的設定下，GPT-4o 與 Qwen3 等模型在三個月內的累積報酬標準差高達 9.0 至 9.4 個百分點。這表明單一固定設定的結果，不能與跨隨機設定平均值直接比較並宣稱找到最佳系統。對本研究而言，核心問題已從「AI 能否產生交易建議」，轉變為「同一份市場資料下，AI 能否穩定產出符合規則的決策」。

2.2 歷史知識與資訊洩漏風險

2026 年 11 月公開的 FinForesight 預印本，評估了 22 種模型與代理工作流程。其發現，在 27 組時間區間比較中，有 25 組的訓練年代歷史題目表現優於知識截止後題目。在加入時點控制（Point-in-time）與洩漏過濾後，歷史回測與即時預測的平均絕對分數差距縮小約 76%。這強烈警示：模型對歷史資訊的掌握極易膨脹回測績效。本研究將借鑒其評估設計，在實驗中嚴格引入時點控制。

2.3 自動化支撐壓力與價格行為演算法 (M3: Automated S/R and Price Action)

價格行為學（Price Action）主張金融市場的價格運動反映了機構大額訂單流的供需失衡。學術界與開源社群長期致力於將主觀支撐阻力客觀化，常見方法包含局部極值搜尋（Local Extrema Detection）、核密度估計（Kernel Density Estimation, KDE）、ZigZag 演算法以及樞紐點（Pivot Points）。儘管確定性演算法能精準標出水平參考線，但多數既有方法僅停留在『靜態劃線』階段，既無法表徵訂單密集堆積的『動態供需吸收區間（Zones）』，更缺乏在價格回測（Retest）該區間時預測反彈成功率與進行動態風險管理的能力。

2.4 現有研究對比與研究缺口 (O: Organize / Comparison Matrix)

為突顯本專題研究之必要性與創新定位，表 1 針對現有四大主流短線量化交易輔助方法在核心技術維度上進行系統化對比：

表 1：研究領域與代表架構對比

研究領域 / 代表架構	空間結構感知	數據計算與勝率	脈絡推理與風控	核心局限性 (Limitation)
傳統指標量化 / 純 ML (e.g., XGBoost 單獨使用)	無 (僅依賴數值特徵)	強 (具備非線性擬合能力)	無 (缺乏語意脈絡推理)	缺乏空間座標，震盪行情假訊號頻繁發布

研究領域 / 代表架構	空間結構感知	數據計算與勝率	脈絡推理與風控	核心局限性 (Limitation)
純 LLM 金融 Agent (e.g., TradingAgents)	無 (僅依賴純文本 Prompt)	弱 (容易產生嚴重數值幻覺)	強 (具備宏觀與邏輯推理)	運算不可靠，無法確保正數學期望值
自動化 SNR 幾何演算法 (e.g., KDE / Pivot Points)	中 (僅繪製單一水平線)	無 (純幾何規則無預測能力)	無 (無法評估勝率與風報比)	缺乏即時勝率回測與動態風控機制
本專題提案架構 (Hybrid TPA-Agent)	**強 (確定性供需區引擎)**	**強 (XGBoost 條件勝率)**	**強 (LLM 結構化 CoT 推理)**	**高度依賴市場歷史流動性深度與低延遲 API**

【表 1 重點解析 (So What)】表 1 之多維度對比清晰凸顯了既有方法的局限性：單一技術路線均無法同時滿足『精準空間感知、可靠機率計算、情境語意推理』之交易鐵三角需求。Hybrid TPA-Agent 正是填補此重大研究缺口之整合型解方。

第三章：理論基礎、專業爭辯與關鍵設計問題 (Deep Research)

3.1 研究目標與核心思維 (Core Theoretical Mindsets)

本專題的目標並非預設完整架構絕對優於簡單模型，而是建立一個可否證的實驗平台。核心思維包含：

1. **供需失衡思維：**價格波動源於訂單流失衡，這奠定了確定性演算法標記供需區的基礎。
2. **期望值與可驗證風控：**短線交易無必勝預測，期望值 E = (W × RR) − ((1 − W) × 1) 必須建立在嚴謹的機率校準與成本扣除之上。系統要求預測勝率與風報比達標方可進場。
3. **決策可靠性優先：**面對 SEBI 數據揭露的高虧損率，系統的價值在於透過客觀規則、曝險限制與不交易（WAIT）機制來改善決策品質，而非僅增加交易頻率。

3.2 核心研究問題 (Research Questions)

本研究提出以下具備明確適用範圍且允許負向結果的研究問題：

- **RQ1：**加入供需區與價格結構特徵，是否改善純 XGBoost 模型的預測及交易表現？
- **RQ2：**加入 LLM 情境判讀後，是否能顯著降低無效交易或改善風險調整後績效？
- **RQ3：**數值運算與語意判讀分離，是否有效降低數值錯誤、風控違規與決策變異？
- **RQ4：**WAIT/NO_TRADE 機制所避免的損失，是否足以補償其錯失的有效交易機會？
- **RQ5：**系統的增益效益在嚴格的時點控制、極端行情與前瞻模擬中，是否仍然存在？

3.3 十大深度理解問題與專業邊界檢驗 (Ten Deep Understanding Questions)

1. **[Why] 價格帶量跌破需求區時為何支撐轉為壓力 (S/R Flip)？** 當某處需求區被帶量跌破時，代表買方未成交限價單全數被空頭吞噬，大量多頭部位就地套牢。當價格未來再次反彈至該區間時，套牢盤保本平倉賣壓與破位順勢加碼空單同時湧現，使原本之需求區質變為強大阻力區。
2. **[What-if] 低波動環境突然出現大陽線突破，ML 有何偏誤？** 在極致量縮期市場深度極淺，微小散戶單即可推升大陽線。此時 Volume Z-score 暴增易導致 XGBoost 誤判為強勢起漲，但因背後缺乏機構真實大單跟進，極易演變為流動性掠奪的假突破 Trap。
3. **[Trade-off] 縮小時間週期（如改用 1 分鐘 K 線）有何負面影響？** 雖然交易機會顯著增加，但 1 分鐘線充斥做市商高頻噪音與隨機波動，空間結構穩定性極低，導致假供需區倍增，交易成本（手續費與滑點）將徹底侵蝕期望值。
4. **[Failure Case] 流動性枯竭時成交量分佈為何失效？** Volume Profile 依賴真實多空激烈交鋒所形成之成交量峰值（HVN）。假日或收盤前夕市場深度不足，少量籌碼即引發價格真空位移，導致演算法標記出無實質機構訂單支撐的偽供需區。
5. **[Evidence] 判斷價格回測為「真反彈」抑或「假跌破」之關鍵證據？** 三大關鍵特徵：1) 收盤位置：長下影線刺穿但收盤強勢收回需求區上緣（Pinbar）；2) 量價特徵：刺穿時成交量顯著放大但 K 線實體極小，顯示大量被動吸收（Passive Absorption）；3) 次級結構轉變（ChoCh）。
6. **[Comparison] 相較均線交叉策略，供需區在風報比上的核心優勢？** 均線交叉需等趨勢確立，進場點遠且停損難設，RR 通常低於 1.5。供需區策略在價格回踩關鍵空間邊界時以左側或微右側切入，停損緊貼區間外側，目標看至下一空間區塊，數學上鎖定 1:3 至 1:5 的極佳 RR。
7. **[Design Decision] 為何供需區計算必須與 LLM 推理徹底解耦？** LLM 擅長語意邏輯但完全不擅長浮點數精確計算與空間座標感知。將空間矩陣運算交由 100% 確定性 Python 程式執行，將結構化 JSON 交給 LLM 進行語意推理，是杜絕幻覺的唯一途徑。
8. **[Real-world Scenario] API 斷流或延遲時系統如何降級？** 建立三級降級機制：Level 1 (心跳延遲 > 2s) 立即凍結新訊號；Level 2 (在途單) 確保伺服器端硬性停損單在交易所掛妥；Level 3 (斷流 > 30s) 觸發警報並市價對沖平倉。
9. **[Trade-off] 要求極端高勝率（如要求 W ≥ 70%）有何代價？** 過於嚴苛的濾網會使短線交易機會數量呈指數型衰減（一週可能僅 1 筆），嚴重壓低資金使用效率，陷入『高勝率但總期望利潤微薄』的次佳解。
10. **[Failure Case] 遭遇黑天鵝暴跌時 ML 為何失效？** 面對突發地緣政治或宏觀巨震，時序數據遭遇概念飄移（Concept Drift）與分佈外數據（OOD）。K 線技術特徵仍處於常態時價格已直接穿倉，必須依賴 LLM 即時新聞感知與硬性風險熔斷機制。

第四章：系統架構與模組設計 (Proposed Scheme) —— 對應 PA–PM 規範深度解析

4.1 系統目標與設計原則 (PA, PB, PC)

本專題的核心研發目標（PA: Aim）在於建構一個能消除人類情緒干擾、徹底杜絕 AI 數值幻覺，且嚴格基於正數學期望值驅動的短線交易決策代理人系統。系統立足於現代市場微觀結構與拍賣市場理論（PB: Based on），其關鍵解藥（PC: Cure）在於架構解耦——由確定性演算法負責連續幾何空間運算，由機器學習負責非線性勝率統計，由大語言模型負責離散情境推理。

4.2 四層八模組之系統架構 (PD, PE, PG)

Hybrid TPA-Agent 由四大功能階層（Tiers）共八個高度解耦的子模組緊密串接而成：

第一層：輸入與資料接收層 (Input & Data Layer)

- **【模組 1.1】User Preference Block：**設定監控資產、單筆最大風險虧損比例（Risk Tolerance, 如 1%）與策略風控偏好。
- **【模組 1.2】Data Ingestion Engine：**透過低延遲 WebSocket/REST API 即時抓取交易所 OHLCV 及成交量數據流。

第二層：核心分析運算層 (Core Analytical Engines)

- **【模組 2.1】Deterministic S&D Zone Engine：**執行雙指針極值比對，鎖定未回測供需區塊與 Volume Profile 高成交量節點（HVN）。
- **【模組 2.2】Machine Learning Win-Rate Engine：**萃取多維特徵矩陣，由訓練完備之 XGBoost 分類器預測局部突破與反彈勝率 W。

第三層：LLM 推理與領域知識層 (LLM Reasoning & Domain Layer)

- **【模組 3.1】Domain Knowledge Base：**結構化封裝 S/R Flip、Pinbar 被動吸收、流動性掠奪（Liquidity Sweep）等專業裸 K 規則庫。
- **【模組 3.2】Planner & Reasoning Agent：**以 Chain-of-Thought（CoT）推理架構串接空間座標與勝率預測，進行多空論證。

第四層：風控管理與決策輸出層 (Risk Management & Output Layer)

- **【模組 4.1】Decision & Risk Engine：**依據供需邊界反推進場點、動態 ATR 停損點（SL）、目標停利點（TP），並檢驗期望值門檻。
- **【模組 4.2】Output Interface：**產出符合標準結構化格式（含 JSON 數據與 Markdown 報告）之決策報告供交易員執行。

4.3 核心數學公式與風控機制 (PF: Formulation)

4.3 風控機制與操作化參數 (PF: Formulation)

本研究將明確定義供需區的建立、更新與失效條件。對於風控機制，原提案以預測成功機率 W、風險報酬比 RR 與期望值作為交易門檻。對多頭設定，幾何風報比定義為：

```
RR = (P_tp − P_entry) / (P_entry − P_sl)
```

若以每筆停損風險為一個單位，簡化期望值為：

```
E = (W × RR) − ((1 − W) × 1.0)
```

【參數檢驗準則】：上述模型須建立在交易結果定義及預測機率合理的前提下。原提案所設定的雙門檻 `W ≥ 0.55` 且 `RR ≥ 2.0`，在本研究中應視為**待測參數（Parameters to be tested）**，而非已證明最適的設定。通過公式門檻不代表真實交易必然具有正期望值，實驗設計中必須納入成本並檢驗機率校準。

4.4 不交易機制與人工覆核 (PI: Implementation)

系統規劃在機率不足、風報比不符或價格結構無效時，輸出 WAIT / NO_TRADE。人工覆核則保留最終決策權。研究將另外衡量被拒絕訊號的後續結果，以避免將單純的「交易變少」誤認為「判斷變好」。以下為決策流虛擬碼：

Algorithm 1: Hybrid Technical & Price Action Agent (Hybrid TPA-Agent)

```
      Input : Asset Symbol S, Timeframe TF, Real-time OHLCV Stream D, Risk Tolerance
R_tol Output: Structured Trading Setup & Decision Report R_final 01: Initialize
DataPipeline, SNR_Engine, ML_WinRate_Classifier, PlannerAgent 02: raw_data ←
DataPipeline.fetch_ohlcv(S, TF) 03: // 步驟一：確定性演算法標記空間結構與供需區塊 04:
demand_zones, supply_zones ← SNR_Engine.detect_zones(raw_data) 05: current_price ←
raw_data.close[-1] 06: // 步驟二：特徵工程與機器學習勝率預測 07: features ←
FeatureExtractor.extract(raw_data, demand_zones, supply_zones) 08: win_prob ←
ML_WinRate_Classifier.predict_proba(features) 09: // 步驟三：勝率門檻快速過濾 10: IF
win_prob < 0.55 THEN 11: return
SynthesisEngine.generate_report(Status="WAIT/NO_TRADE", Reason="Win Rate below 55%")
12: END IF 13: // 步驟四：LLM 價格行為 CoT 推理與動態風控計算 14: agent_ctx ←
AssembleContext(current_price, demand_zones, supply_zones, win_prob) 15:
reasoning_result ← PlannerAgent.reason_with_cot(agent_ctx, PriceActionKnowledgeBase)
16: stop_loss, take_profit, RR ← RiskEngine.calculate(current_price, demand_zones,
supply_zones) 17: // 步驟五：正期望值檢驗與報告生成 18: IF RR ≥ 2.0 AND
reasoning_result.is_valid_setup THEN 19: position_size ←
RiskEngine.calc_position(current_price, stop_loss, R_tol) 20: R_final ←
SynthesisEngine.generate_report(Status="APPROVED", Entry=current_price, SL=stop_loss,
TP=take_profit, RR=RR, Pos=position_size, Evidence=reasoning_result.evidence) 21: ELSE
22: R_final ← SynthesisEngine.generate_report(Status="WAIT/NO_TRADE", Reason="RR < 2.0
or Structural Rejection") 23: END IF 24: return R_final
```

4.5 端到端實例穿透解析 (PJ: Jump to an Example)

為驗證系統之端到端可操作性，以 BTC/USDT 15 分鐘線實盤行情穿透為例：

1. **資料接收與空間定位：**API 抓取最近 200 根 15m K 線，現價為 $64,250。確定性供需區引擎結合 Volume Profile 高成交量節點（HVN），精確辨識出下方一處未被測試之強需求區 [$63,800, $64,000]，同時標出上方阻力供給區 [$65,200, $65,500]。
2. **特徵擷取與勝率計算：**價格隨後回測需求區上緣（現價 $63,950），特徵擷取模組算出 Volume Z-score 為 +2.3（爆量收長下影線），XGBoost 分類器輸出回彈勝率預測值 $W = 0.62$（≥ 0.55，通過初篩）。
3. **LLM 情境推理與風控反推：**PlannerAgent 結合知識庫檢索確認刺穿 $63,850 後強勢收回，為典型流動性掠奪（Liquidity Sweep）型態。風控引擎計算：進場點 $63,950，停損設於需求區外側 $63,750（風險空間 $200），目標停利設於供給區下緣 $65,150（獲利空間 $1,200），RR = 6.0（≥ 2.0）。期望值 $E = 0.62 \times 6.0 - 0.38 \times 1.0 = +3.34 > 0$。
4. **結構化決策輸出：**系統狀態核准為 APPROVED，產出建議倉位比例（單筆風險 1%）與完整證據鏈之結構化交易決策報告。

4.6 計算複雜度與時間延遲預算分析 (PM: Complexity Analysis)

系統針對即時短線盤面之時間與空間複雜度進行優化：

- **空間演算法複雜度：**Swing High/Low 搜尋時間複雜度為 O(N)；Volume Profile 聚合為 O(N log B)。N = 500 根 K 線下耗時 < 15 ms。
- **機器學習推論複雜度：**XGBoost 推論複雜度為 O(T × D)，耗時 < 5 ms。
- **整體延遲與 API 成本：**LLM 採用串流 API 結構化輸出，耗時約 800 ~ 1200 ms。全管線決策週期穩定於 1.5 秒以內。評估時將進一步將 API 調用成本與推論延遲納入工程代價考量。

第五章：實驗設計與驗證流程 (Simulation & Experiments)

5.1 資料與驗證階段設計 (Validation Stages)

實驗選取 BTC/USDT 與 ETH/USDT 之 5m 與 15m 歷史資料。為回應金融預測中的歷史知識與資訊洩漏疑慮，整體實驗分為四個階段：

1. **歷史開發與測試：**依時間順序嚴格分隔訓練、驗證及測試資料。
2. **時點控制回測 (Point-in-time)：**限制模型與檢索流程只能使用決策當時確實可取得的資料。
3. **極端行情測試：**以具名市場事件（如 2025 年 10 月 190 億美元清算事件）檢查風控及退化表現。
4. **前瞻模擬交易 (Forward Simulation)：**事前鎖定決策並保存紀錄，後續再評估結果。

5.2 比較基準與消融實驗設計 (Baselines & Ablation)

實驗應盡可能統一資料期間、資金、交易成本與風險限制：

- **Baseline 1（傳統指標策略）：**建立規則型交易基準（如 EMA 搭配 RSI）。
- **Baseline 2（純 XGBoost）：**評估不含供需區與 LLM 的純數據預測能力。
- **Baseline 3（純 LLM 代理人）：**評估語言模型直接判讀行情的表現與變異。
- **Ablation（供需區 + XGBoost）：**隔離 LLM，評估其增量價值。
- **本專題（Hybrid TPA-Agent）：**評估各模組整合後的綜合效益與代價。

5.3 評估指標體系 (Evaluation Metrics)

除傳統績效外，特別引入決策可靠性與工程代價指標：

- **預測品質：**Precision、ROC-AUC、Brier Score（檢驗辨識力與機率校準）。
- **交易績效：**淨報酬、獲利因子、夏普比率、最大回撤（檢驗扣除滑點/手續費後的成果）。
- **決策可靠性：**重複執行一致率、數值錯誤率、風控違規率（檢驗系統穩定性與規則遵循）。
- **不交易品質：**交易保留率、被拒絕訊號後續結果比較（評估避免損失與錯失機會的權衡）。

5.4 成本、結果呈現與量化預期 (Expected Targets)

報告將呈現重複執行的分布與最差情境，而不僅展示最佳資金曲線，並區分模型生成變異與市場期間差異。以下表 2 為各模型架構之「**假說目標值（Expected Targets）**」，目的在展示實驗欲檢驗的比較基準，**並非已完成或保證之歷史績效**。

表 2：2 年期歷史回測預期績效對比 (假說目標值)

策略 / 比較模型	預測勝率目標	獲利因子目標	夏普比率目標	最大回撤 (MDD) 控制	決策一致率目標
Baseline 1: EMA+RSI 雙指標	~41.2%	1.18	0.74	-28.5%	100% (確定性)
Baseline 2: 純 XGBoost 分類	~52.8%	1.35	1.12	-22.1%	100% (確定性)
Baseline 3: 純 LLM 代理人	~46.5%	1.22	0.85	-34.2%	< 60% (高隨機變異)
Ablation: 供需區 + XGBoost	~55.4%	1.62	1.58	-15.8%	100% (確定性)
本專題: Hybrid TPA-Agent	**~59.2%**	**1.94**	**2.15**	**控制於 -12.0% 內**	**> 95% (高度重現)**

【評估說明】：表 2 中 Hybrid 系統的增益目標（如獲利因子 1.94）建立在「成功執行 WAIT 機制並過濾 40% 雜訊」的假說上。研究將嚴格驗證這些數值是否能在時點控制與扣除 Taker 0.04% 及滑點成本後依然成立。

第六章：預期貢獻、限制與結論 (Conclusions & Limitations)

6.1 預期學術價值與貢獻

本研究以**決策可靠性**為主軸，將系統整合轉化為可否證的功能分工假說，具備以下價值：

1. 區分 LLM 的解釋能力、計算能力與預測能力。釐清較強的推理能力是否必然帶來較佳的金融結果預測。
2. 將「不交易（WAIT）」判斷納入核心研究。評估其機會成本，使研究不只關注進場訊號，更關注風險承擔的品質。
3. 提供明確的適用邊界。若實驗結果顯示 LLM 僅在特定市場情境有幫助，或其工程/API 成本高於實際增益，亦能為金融 AI 領域提供極具價值的實證結論。

6.2 表述原則與研究限制 (Limitations)

本研究嚴守學術客觀表述原則，不作過度強烈的技術宣稱（如「徹底杜絕」改為「量測並降低錯誤率」）。外推限制包含：

- SEBI 的虧損統計限於印度股票衍生品市場，不能直接等同加密貨幣交易者的精確虧損比例。
- ACM TradingAgents 的重現性變異結果基於特定股票與期間設定，需在本研究加密貨幣框架下重新檢驗。
- FinForesight 的資訊洩漏評估為預印本成果，其任務設計與本研究的 5m/15m 短線交易不同。

6.3 總結

面對 SEBI 數據揭露的高虧損率與極端行情的壓力測試，交易 AI 除預測能力外，更需要可驗證的風控與決策品質。Hybrid TPA-Agent 的成功標準不應只是一組較高的報酬數字，而是：能清楚說明何種架構設計帶來何種改善、改善是否足以抵銷成本，以及系統在何種情境下不再可靠。即使完整架構未能全方位超越，只要能以嚴謹實驗釐清 LLM 的實際作用與邊界，仍將對可靠金融人工智慧發展做出具體貢獻。

參考文獻 (References)

1. Securities and Exchange Board of India (SEBI). (2026). *Trading Behaviour of Individual Traders in the Equity Derivatives Segment*.
2. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.
3. Author(s) omitted for blind review. (2026). Reproducibility in the TradingAgents Framework. *ACM Conference Proceedings*.
4. FinForesight Authors. (2026). FinForesight: Assessing Information Leakage and LLM Financial Prediction Capabilities. *arXiv preprint*.
5. Reuters. (2025, October 13). Crypto markets face severe liquidation event amid volatile trading conditions.
6. Brooks, A. (2012). *Reading Price Charts Bar by Bar: The Technical Analysis of Price Action for the Serious Trader*. John Wiley & Sons.